

# NeuroEvolution of Augmenting Topologies (NEAT)

## Steuerung eines Mario Jump & Run Spiels

Jan Urfei

Bonn-Rhein-Sieg University of Applied Sciences  
Grantham-Allee 20  
53757 Sankt Augustin, Germany  
jan.urfei@inf.h-brs.de

Tim Lügger

Bonn-Rhein-Sieg University of Applied Sciences  
Grantham-Allee 20  
53757 Sankt Augustin, Germany  
tim.luegger@inf.h-brs.de

### ABSTRACT

Ziel war es eine Mario Spielfigur mit bestimmten Szenarien zu trainieren, sodass diese dann das/die Level best möglichst lösen kann.

### 1. ASSIGNMENT

Aufgabe war es den für die HeartRate Prediction implementierten NEAT Algorithmus[1] anzupassen, dass er ein Problem eines ausgesuchten Projektes löst.

In diesem Projekt wurde ein Simulator verwendet, der dem Jump & Run Spiel Super Mario Bros. nachempfunden ist. Ziel dieses Spieles ist eine Figur in einer 2D-Welt zu steuern und möglichst das Ende des Levels zu erreichen. Dabei existieren Hindernisse wie Schluchten oder Monster die es zu überwinden gilt.

Zielsetzung war es zu ergründen, ob es NEAT erlaubt ein Netzwerk zu trainieren, welches basierend auf den Informationen aus dem aktuellen Sichtfeld die Spielfigur steuert, um ans Ende des (statischen) Levels zu gelangen.

Als Trainingsdaten wurde sich zunächst auf ein generiertes Level beschränkt, welches nur Blöcke, Schluchten oder erhöhte Ebenen enthielt, die es zu überspringen galt.

Das Sichtfeld besteht aus einem Gitter, zentriert um die Spielfigur herum (siehe Figure 1). Die Objekte/Kacheln im Level unterscheiden sich anhand ihrem Typ (z.B Boden, Wand) und ihrer Position.



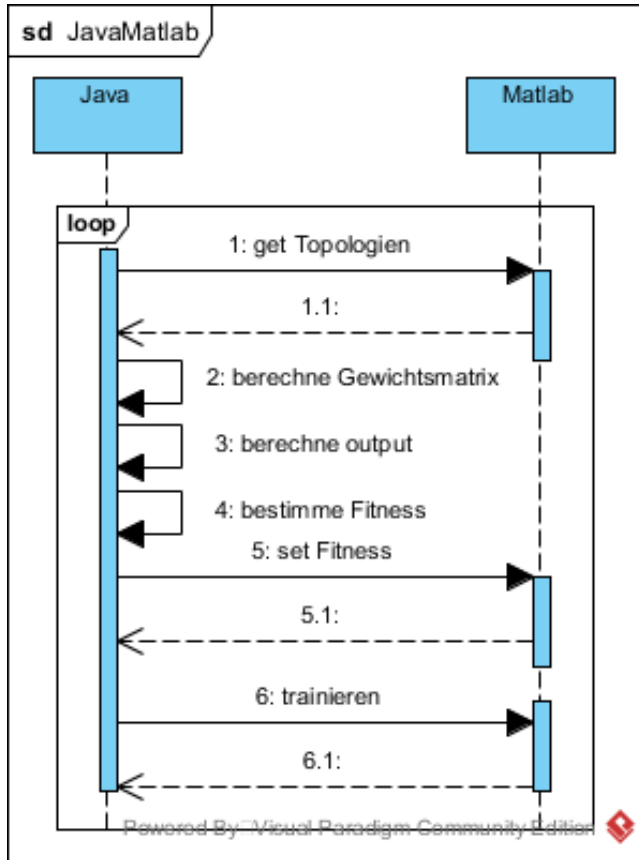
Figure 1: Umgebungsblöcke der Spielfigur für den Input

### 2. APPROACH

Im Gegensatz zum NEAT Paper [1] wird eine Mutation verwendet, die Kanten wieder deaktivieren kann, damit die Topologien minimiert werden, falls nicht alle Eingaben aus dem Sichtfeld benötigt werden. Des weiteren wurde auf Fitnesssharing verzichtet.

Um die Kommunikation zwischen dem Simulator und Matlab herzustellen wurde die MATLAB API for Java verwendet. Diese erlaubt es aus Java heraus mit der Matlab Session zu interagieren. In jeder Iteration wird die aktuelle Population aus dem Workspace geladen und bei der Ausführung des Simulators anhand des aktuellen Sichtfelds der Spielfigur der Output bzw. den daraus resultierenden Tastendruck. Um die Kommunikation zwischen Matlab und Java möglichst gering zu halten ist die Berechnung der Netze in Java mittels der Matrizen Bibliothek ND4J implementiert. Hat der die Spielfigur das Ende des Levels erreicht, ist die Spielzeit abgelaufen, die Spielfigur in eine Schlucht gefallen oder stecken/steht geblieben wird die fitness auf den erreichten Levelfortschritt gesetzt (x-Position). Außerdem wird bei Topologien, die das Ende des Levels erreichen, die restliche Spielzeit addiert um die Geschwindigkeit in der das Level abgeschlossen wird zu belohnen. Die Fitnesswerte werden zurück in den Matlab Workspace geschrieben und die Mutation mittels NEAT durchzuführen. Danach beginnt der Prozess von neuem. In der folgenden Abbildung (Figure 2) ist der

Ablauf nochmals veranschaulicht.



**Figure 2: Kommunikation und Ablauf zwischen Java und Matlab**

Das Sichtfeld der Spielfigur ist auf 15x15 (Breite x Höhe) Felder begrenzt bzw. auf 7x15 also nur die rechte Hälfte des Sichtfeldes, da im ausgewählten Level keine Rückwärtsbewegung notwendig ist.

Um die Eingabemenge gering zu halten wurden ähnliche Kacheln mit dem selben Eingabewert versehen (z.B. Boden, Fels) sowie unwichtigeren Kacheln geringere Eingabegrößen vergeben.

### 3. EXPERIMENTS


Unsere Experimente sind jeweils 5 mal durchgeführt worden. Dabei wurden pro Experiment 1-2 Parameter verändert und getestet. Mehr als 5 Wiederholungen wären für eine aussagekräftigere Auswertung sinnvoll gewesen, aber Aufgrund der Dauer der Simulation, bei den zusätzlich 6 verschiedenen Parametrierungen, nicht realisierbar im Rahmen des Projektes.

#### 3.1 Lernraten

Mit dem Folgenden Experiment (Figure 3) wurde ausgewertet, welcher Einfluss die Lernrate bzw. die Wahl der Standardabweichung bei der Normalverteilung der Gewichtsmutation hat. Sowie die Auswirkungen des zufälligen Zurücksetzens von Gewichten. Beispielsweise werden bei einer Gewichtsmutationsrate (wm) von 0.9, 90% der zu mutierenden Gewichte mit einer normalverteilten Zufallszahl mit der an-


gegebenen Standardabweichung (std) addiert. Die anderen 10% werden zufällig neu gesetzt.

Aus Figure 3 lässt sich ablesen, dass es effektiver ist nur einen geringen Prozentsatz von Gewichten zufällig neu zu Wählen z.B. 2% anstatt 10%.



**Figure 3: Durchschnitt Elite Fitness**

Man erkennt (siehe Figure 4), dass wenn weniger Gewichte neu gewählt wurden, wesentlich früher Netze gefunden werden, welches das Level erfolgreich beenden. Die Überschneidung der beiden Durchläufe std=0.0002, std=0.002 mit wm=0.98 deuten daraufhin, dass es sinnvoll gewesen wäre mit einer nicht zu geringen Standardabweichung zu starten diese dann aber ab ca. 100 Iterationen zu reduzieren.




**Figure 4: (Keine) Neuwahl der Gewichte**

Das zufällige neu Wählen der Gewichte ist essenziell für den Lernerfolg. Die Spielfigur schafft ansonsten im Level nur knapp über 500 Pixel weit. Werden zu viele Gewichte neu gewählt, variieren die Topologien zu stark, sodass sich kein großer Lerneffekt einstellt.


### 3.2 Controls

Im folgenden Experiment haben wir uns angeschaut, welcher Threshold für den Output genommen werden sollte, damit eine Taste gedrückt wird oder nicht. Vermutet hatten wir, dass der Threshold 0,5 am besten sein sollte, da dort der Anstieg der Aktivierungsfunktion am größten ist. In Figure 5 lässt sich aber erkennen, dass der Durchschnitt über die Elite bei 5 Versuchen bei unterschiedlichen Lernraten immer schlechter ist, als wenn man den Threshold auf 0,2 setzt und dort die unterschiedlichen Lernraten testet.



**Figure 5: Durchschnitt der Elite bei 5 Wiederholungen beim Vergleich von unterschiedlichen Thresholds im Zusammenspiel mit unterschiedlichen Lernraten**

Der Boxplot zu dem Experiment zeigt, dass nicht nur die Elite schlechter ist mit einem Threshold von 0,5, sondern dass die Elite nach 500 Iterationen (siehe Figure 6) deutlich stärker verteilt ist. Hieraus lässt sich auch ablesen, dass in allen Setups zwar eine Lösung für das Level gefunden werden kann, aber das nicht zwingend der Fall sein muss. So kann es bei einem Threshold von 0,5 und einer Lernrate von 0.0002 auch passieren, dass die Elite nicht mal 35% des Levels schafft. Der rechte Boxplot in Figure 6 zeigt, dass nach 500 Iterationen immer eine Lösung für das Level vorhanden ist, weshalb diese Parameter gewählt werden sollte. Allein aus Figure 5 hätte man das nicht direkt entscheiden können, ob die blaue oder die gelbe Kurve die besseren Parameter sind, aber aus dem Boxplot ist dies doch klar ersichtlich.




**Figure 6: Boxplot der Elite nach 500 Iterationen von den unterschiedlichen Setups**

Des Weiteren wurden verschiedene Varianten der Steuerung (Tastatureingaben) verglichen (siehe Figure 7). Mit der Predefined Methode wurde den Ausgabeneuronen Tastenkombinationen zugeordnet. In jedem Zeitschritt wird dann die, mit der aktuell höchsten Aktivierung, ausgeführt. Bei der Threshold Methode wird jedem Ausgabeneuron genau eine Taste zugeordnet. Wenn ein Neuron den gewählten Threshold überschreitet wird sie gedrückt.

Es wurden die Tasten 'Jump', 'Run Right', und 'Sprint' benutzt. Das es für die Level nicht erforderlich ist, die Spielfigur nach links zu bewegen, wurde auf 'Run Left' verzichtet.

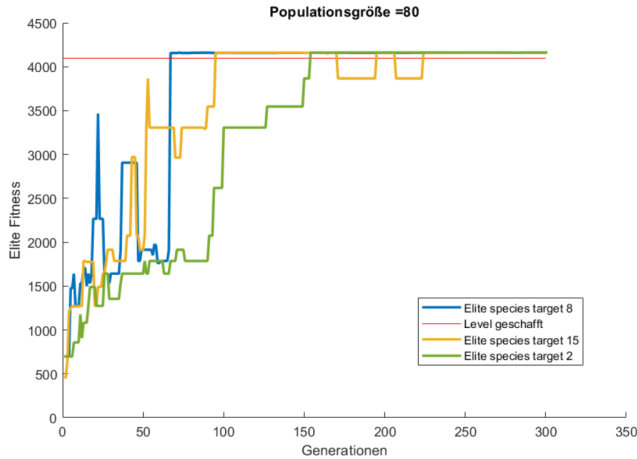
Wie erwartet funktioniert die Predefined Methode (schon von beginn an) am besten. Für bestimmte Schluchten ist es für die Spielfigur notwendig möglichst weit zu springen, daher muss 'jump' + 'run Right' gleichzeitig gedrückt werden. Das gleichzeitige drücken der beiden Tasten muss aber bei der Threshold Methode erst erlernt werden wo hingegen bei der Predefinde Methode dieses Verhalten schon vordefiniert ist.



**Figure 7: Steuervarianten Predefined vs Threshold**


### 3.3 Experiment Verhältnis Spezienziel & Populationsgröße

In einem Experiment haben wir uns angeschaut, wie sich die Elite bei verschieden starker Spezienbildung entwickelt. Dazu haben wir eine feste Populationsgröße gewählt und Messungen mit unterschiedlichen Spezienzielen durchgeführt. In Figure 8 ist genau dies zu sehen bei einer Populationsgröße von 80 und Spezienzielen von 2/ 8 und 15. D.h. durchschnittlich waren 40/ 10 oder 5 Topologien in einer Spezie. Dabei kann man sehen, dass wenn zu viele Topologien in einer Spezie sind, sich die Elite nicht gut entwickelt (siehe grüne Kurve in Figure 8), da sich Spezien kreuzen die sehr unterschiedlich sind.



**Figure 8: Experiment mit fester Populationsgröße aber unterschiedlichen Spezienzielen**

Wenn allerdings zu wenig Topologien in einer Spezie sind ist das für die Entwicklung der Elite auch nicht förderlich. In Figure 9 sind durchschnittlich 2 Topologien in einer Spezie. Dort kann man feststellen, dass einmal kaum neue Lösungen erzeugt werden (erkennbar durch eine relativ gleichbleibende horizontale Linie am Anfang). Wenn durch Zufall eine neue viel bessere Lösung gefunden wird, passiert es relativ oft, dass diese wieder verworfen wird. Das kommt dadurch, dass die Spezien relativ oft aussterben und sich nicht durchsetzen, da im Schnitt nur 2 in einer sind. Dazu kommt, dass das Kopieren der Elite einer Spezie erst ab einer Größe von 5 passiert, wodurch so auch nicht der beste behalten wird.




**Figure 9: Verlauf der Elite bei einem Verhältnis von 0,5, sodass im Durchschnitt 2 Spezien existieren**

### 3.4 Multilevel Training (Generalisierung)

Um die Generalisierbarkeit des Verfahrens zu testen, wurden 100 Trainings und 100 Testlevel generiert. Aufgrund der Dauer der Simulation wurden 10 Level aus den 100 Trainingsleveln ausgesucht. In jeder Iteration wurde die Simulation auf den 10 Leveln ausgeführt und die Fitnesswerte aufaddiert.


In Figure 10 ist dazu die durchschnittliche Elite Fitness über 10 Level dargestellt. Da sich schon nach wenigen Iterationen die Fitnesswerte stabilisiert haben und sich die Fitness auf den Testdaten auch nicht verbessert hat, wurde ab ca. der 1200 Iteration, in jeder Iteration, ein zufälliges Level mit einem aus den generierten Trainingslevel ausgetauscht (Erkennbar an dem sofortigen Abfall der durchschnittlichen Fitness).



**Figure 10: Fitness der Elite beim Training (Durchschnitt über 10 Level)**

Bei Betrachtung der Fitnesswerte der 100 Testlevel in Figure 11 erkennt man zwar, dass ein paar wenige Level gute Ergebnisse erzielen, aber insgesamt die Generalisierung in diesem Experiment nicht ausreichend erkennbar ist.

Um ein Aussagefähigeres Ergebnis zu erzielen, müsste zum einen Trainingsmenge als auch die Anzahl der Trainingsiterationen wesentlich erhöht werden. Diese Anforderung war aber nicht erfüllbar, da es nicht praktikabel war den Simulator umzuschreiben um ihn parallelisierbar zu machen.



**Figure 11: Fitness der Elite auf 100 zufälligen Testleveln**

## 4. CONCLUSION

Abschließend hat sich herausgestellt, dass NEAT auf einem speziellen Level sehr gut funktioniert. Dort wird eine Lösung gefunden, die auch maximal gut optimiert wird, so dass Mario das Level in kürzester Zeit schafft. Bei dem Versuch auf mehreren Level hat sich NEAT als nicht ganz so gut erwiesen (zumindest bei der Anzahl an Iterationen, die in unserem Bereich des Möglichen waren). Dort war kein großer Lerneffekt feststellbar. Zudem kam dazu, dass der Simulator nicht gut parallelisierbar ist, wodurch wir auch nicht mehr Iterationen in kürzerer Zeit durchführen konnten. Durch dieses Experiment konnten wir nicht feststellen, dass sich Mario auf Grund seiner Umgebung fortbewegt oder nur Bewegungsabläufe speichert.

Außerdem zeigte sich deutlich, dass die Speziesbildung für den Algorithmus sehr wichtig ist und man bei dieser auf die Granularität achten muss. Die Spezies dürfen nicht zu speziell aber auch nicht zu allgemein sein. Genauso zeigte sich, dass für das finden besserer Lösungen das Setzen von neuen zufälligen Gewichten unabdingbar ist.

Was die Steuerung angeht waren vordefinierte Tastenkombinationen die beste Wahl, was aber auch daran lag, dass dadurch zusätzliches Wissen mit in den Algorithmus eingeflossen ist.

Insgesamt lässt sich sagen, dass der Algorithmus sehr viele Stellschrauben hat, die man bei einem konkreten Problem genau einstellen muss und das man Laufzeiten verkürzen kann, in dem man sich bei dem Input und der Interpretation des Outputs Gedanken macht, um dem Algorithmus über das Spiel zusätzlich Wissen zu geben.

## 5. REFERENCES

- [1] K. O. Stanley and R. Miikkulainen. Evolving Neural Networks through Augmenting Topologies. *Evolutionary Computation*, 10(2):99–127, 2002.